



在预测电影评分这个例子中, 我们应该预测用户会给他没有看过的电影打多少分, 再推荐他会打高分的电影给他。



我们预测问号上的喜爱程度,是将电影中的成分当作特征,再添加一个截距项 1,得到x向量,再用某种方式得到参数向量,之后我们利用参数向量的转置乘 以x向量,得到了喜爱程度。

为了得到sita参数向量,最小化代价方程。将预测喜爱值看作线性回归问题,得到代价方程,加入正则化项,截距项不计入正则化项,所以k从1开始。代价方程中去掉m,因为是常数项。



第二个代价方程针对所有用户。

利用梯度下降来求解参数向量

k=0时没有正则化项, 当k! =0, 正则化项会对导数产生影响, 所以更新梯度下降方程针对两种情况。

Optimization algorithm:
$$\min_{\theta^{(1)},...,\theta^{(n_u)}} \frac{1}{2} \sum_{j=1}^{n_u} \sum_{i:r(i,j)=1}^{n} \left((\theta^{(j)})^T x^{(i)} - y^{(i,j)} \right)^2 + \frac{\lambda}{2} \sum_{j=1}^{n_u} \sum_{k=1}^{n} (\theta^{(j)}_k)^2$$
Gradient descent update:
$$\theta_k^{(j)} := \theta_k^{(j)} - \alpha \sum_{i:r(i,j)=1}^{n} ((\theta^{(j)})^T x^{(i)} - y^{(i,j)}) x_k^{(i)} \left(\text{for } k = 0 \right)$$

$$\theta_k^{(j)} := \theta_k^{(j)} - \alpha \left(\sum_{i:r(i,j)=1}^{n} ((\theta^{(j)})^T x^{(i)} - y^{(i,j)}) x_k^{(i)} + \lambda \theta_k^{(j)} \right) \left(\text{for } k \neq 0 \right)$$

$$\frac{\lambda}{\lambda} \theta_k^{(j)} = \frac{\lambda}{\lambda} \theta_k^{(j)} \left(\frac{\lambda}{\lambda} \theta_k^{(j)} \right) \left(\frac{\lambda}{\lambda} \theta_k^{(j$$